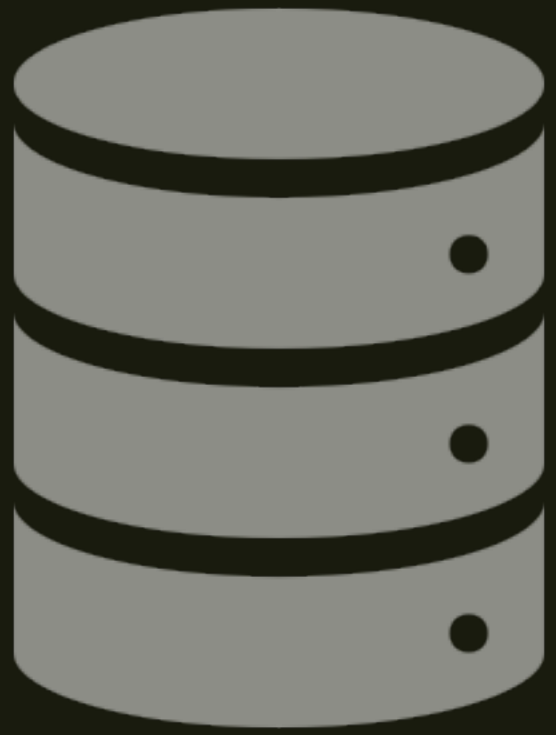

FORMATOS DE ARQUIVOS E DADOS

Big Data

FORMATOS DE ARQUIVOS E DADOS

Ementa

- Contexto em Big Data
- Formatos textuais
- Formatos binários
- Formatos colunares
- Vetorização

CONTEXTO

Contexto

1

Arquivos localizados em diferentes nodos do *cluster*

2

Arquivos particionados em blocos distribuídos no *cluster*

3

O particionador não conhece o conteúdo dos arquivos

HDFS

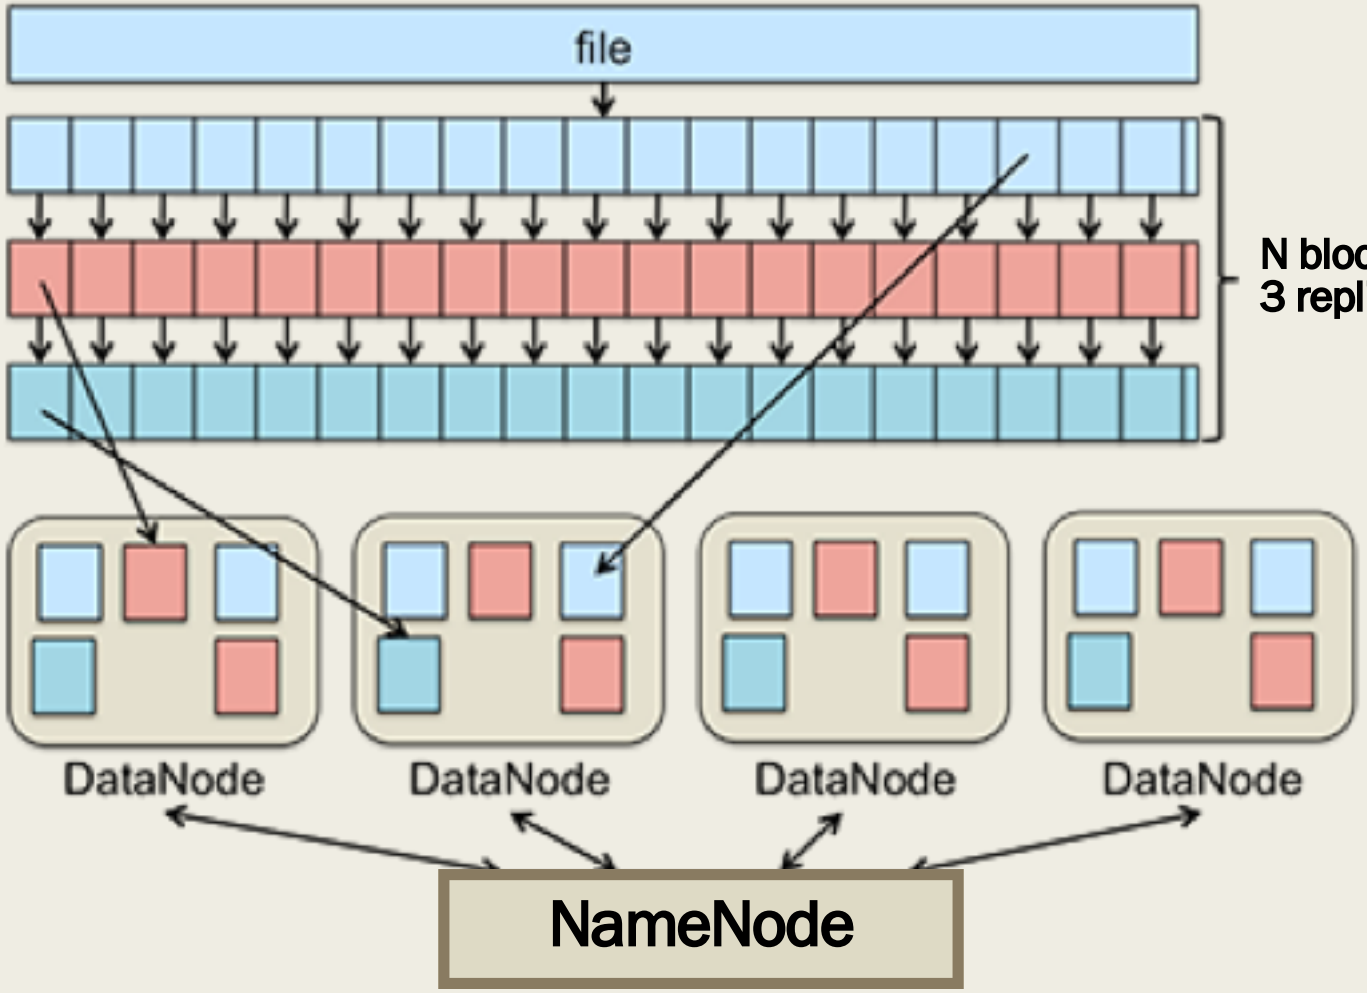

- Arquivo é automaticamente dividido em blocos
- Tamanho dos blocos definido na escrita
  - *Ex:64MB, 128MB, 1GB*
- Localização dos blocos privilegia a distribuição heterogênea

S3 (S3A)

- Multipart
  - *Conteúdos acima de 5MB até um limite de 5TB*
- Recomendação de utilizar S3 como origem e destino final dos dados, mas com HDFS para armazenamentos intermediários

FORMATOS TEXTUAIS

Arquivos CSV

- Formato onipresente
  - *Suportado por praticamente qualquer ferramenta analítica*
  - *Provavelmente sua única vantagem* ☺
- Falta de padronização
- Tamanho
- Custo de transformação
- Carência de recursos para dados hierárquicos
- https://donatstudios.com/Falsehoods-Programmers-Believe-About-CSVs
- Exemplo arquivo TED talks

Arquivos CSV – Detalhes de implementação

- Cabeçalho dos arquivos
  - *Dentro deste contexto de arquivos distribuídos, como tratar a primeira linha, de cabeçalho?*
- Definição de *schema* do arquivo
  - *Como determinar o schema do dataset CSV de forma dinâmica?*

Arquivos CSV – Detalhes de implementação

- Spark, na implementação da leitura de conteúdo textual, segue utilizando a implementação do Hadoop
  - https://github.com/apache/spark/blob/master/sql/core/src/main/scala/org/apache/spark/sql/execution/datasources/csv/CSVDataSource.scala
- O que acontece quando uma linha está dividida em 2 partições?
  - https://github.com/hanborq/hadoop/blob/master/src/mapred/org/apache/hadoop/mapreduce/lib/input/LineRecordReader.java

Arquivos JSON

- Popular em ambientes web
- Estrutura hierárquica
  - *Somente suporta arquivo no formato registro por linha*
- Formato de APIs Web, eventos, logs
- Vimos nos arquivos da Amazon

Compressão

- Reduz volume
- Por arquivo
  - *Gzip, Bzip – boa compressão, mais lento*
  - *Sendo por arquivo, não possibilita leitura dos blocos em paralelo*
- Por blocos
  - *Snappy, LZO*
  - *Tradeoff de compressão por velocidade*
  - *Compressão ocorre em blocos*

FORMATOS BINÁRIOS

Apache Avro

- Sistema de serialização de dados
  - ***Serialização de objetos***
  - ***Formato de arquivo (avro datafile)***
  - ***Schema-on-read & schema-on-write (schema evolution)***
  - *(opcional) Geração de código para representação dos schemas*
- Foco na portabilidade
  - *Neutro quanto a linguagens de programação e meios de comunicação*
- Schema faz parte do conteúdo serializado
- Compressão em blocos

FORMATOS COLUNARES

Apache Parquet

- Formato de armazenamento colunar que pode armazenar com eficiência dados aninhados (hierárquicos)
  - *Inspirado no Google Dremel*
- Eficiente em termos de armazenamento por combinar duas técnicas
  - *Compressão, em blocos*
  - *Encoding, varia conforme o tipo de dado armazenado*

- Formato do arquivo definido em *Schema*, similar ao Apache Avro

Apache Parquet

- Block – Grupo de registros
- Column chunk – Grupo de colunas
- Page – valores de uma coluna
  - *Onde o encoding é aplicado*
    - Delta
    - Run-length
    - Dictionary
    - Bit packing
- Metadados no Footer

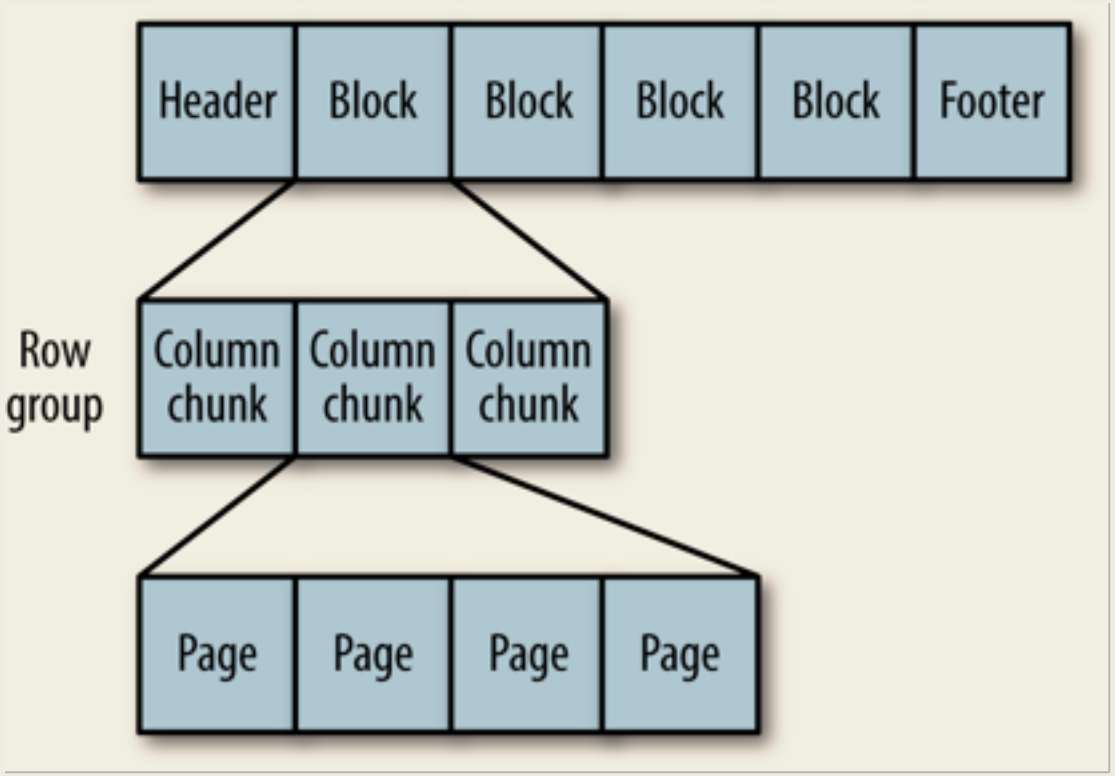

Apache Parquet

- Formato colunar possibilita filtros na leitura do arquivo
  - *Column Projection*
  - *Predicate Pushdown*
- Demo em aula

Apache ORC

- Entraremos em mais detalhes com o PRESTO e Athena